

INSTITUTO DE ENSINO SUPERIOR THATHI

MÁRCIO RENAN NUNES GOMES

ANÁLISE DE DESEMPENHO ACADÊMICO UTILIZANDO REDES
NEURAIS ARTIFICIAIS

Araçatuba
2006

INSTITUTO DE ENSINO SUPERIOR THATHI

MÁRCIO RENAN NUNES GOMES

ANÁLISE DE DESEMPENHO ACADÊMICO UTILIZANDO REDES
NEURAIS ARTIFICIAIS

Monografia realizada para
apresentação do Trabalho de
Conclusão do Curso de
Ciência da Computação,
orientada pelo professor Dr.
Renato Ferrari Pacheco.

Araçatuba
2006

INSTITUTO DE ENSINO SUPERIOR THATHI

MÁRCIO RENAN NUNES GOMES

ANÁLISE DE DESEMPENHO ACADÊMICO UTILIZANDO REDES
NEURAIS ARTIFICIAIS

COMISSÃO JULGADORA

MONOGRAFIA DE TRABALHO DE CONCLUSÃO DE CURSO

Presidente e Orientador
2º Examinador
3º Examinador
4º Examinador

Araçatuba, ____ de _____ de _____.

*Dedico este trabalho a todos aqueles
que direta ou indiretamente
contribuíram para que este pudesse
ser realizado com sucesso.*

AGRADECIMENTOS

Primeiramente agradeço a Deus, por mais uma conquista.

À minha mãe Conceição e minha avó Iraci, por estarem ao meu lado todos esses anos apoiando, pois sem elas não teria chegado até aqui.

A todos meus professores, que contribuíram para minha formação, ensinando não somente as disciplinas do curso, mas também maneiras de como encarar a vida.

Ao meu orientador, Professor Renato, pelo empenho em ajudar e dedicação à causa.

Aos meus companheiros da turma, pela convivência durante estes quatro anos, que muito contribuiu para meu crescimento pessoal.

À minha namorada Ana Flávia, pelo carinho e compreensão, afinal, “por trás de um grande homem, existe uma grande mulher”.

RESUMO

O presente trabalho tem por objetivo o estudo e a implementação de uma rede neural artificial (RNA) para uma aplicação de uso acadêmico, que seja capaz de encontrar características nos alunos com base em seus históricos escolares. A rede neural artificial deve traçar um perfil para cada aluno e agrupá-los conforme suas notas, mantendo alunos com perfis semelhantes em grupos semelhantes. O modelo de RNA utilizado foi Redes SOM (*Self-organizing Maps* – Mapas auto-organizáveis) de Kohonen, ou simplesmente Rede de Kohonen. Para que o sistema desenvolvido pudesse retratar dados reais, com base em notas reais, foi utilizado o histórico escolar das turmas formadas em 2004 e 2005, que foram fornecidos pela Secretaria das Faculdades Thathi. Os resultados obtidos foram satisfatórios, podendo ser observados através de gráficos, onde os grupos formados e os alunos que pertencem aos grupos são nitidamente visíveis.

Palavras-Chave: Inteligência Artificial; Redes Neurais Artificiais; Redes SOM (Kohonen).

SUMÁRIO

LISTA DE FIGURAS	7
1 INTRODUÇÃO	8
2 INTELIGÊNCIA ARTIFICIAL (IA)	10
2.1 Abordagens da Inteligência Artificial	10
3 REDES NEURAIS ARTIFICIAIS (RNAs)	12
3.1 Neurônio	12
3.2 Arquitetura de uma RNA	13
3.3 Aprendizagem	14
3.4 Redes SOM (<i>Self-organizing Maps</i>)	16
3.4.1 <i>Arquitetura das Redes SOM</i>	16
3.4.2 <i>Treinamento das Redes SOM</i>	17
3.5 Demonstração do funcionamento das Redes SOM	18
4 DESENVOLVIMENTO	23
5 RESULTADOS	27
5.1 Outras Análises	31
6 CONCLUSÕES	34
6.1 Trabalhos Futuros	34
7 BIBLIOGRAFIA	35
APÊNDICE	36

LISTA DE FIGURAS

Figura 1 – Representação matemática do neurônio – McCulloch e Pitts	12
Figura 2 – Camadas de uma Rede Neural Artificial (RNA)	13
Figura 3 – Treinamento Supervisionado	15
Figura 4 – Treinamento Não-Supervisionado	15
Figura 5 – Camadas que compõem a rede de Kohonen	16
Figura 6 – Algoritmo treinamento SOM	17
Figura 7 – Redução da região de vizinhança	18
Figura 8 – Demonstração Rede SOM: Parte 1	19
Figura 9 – Demonstração Rede SOM: Parte 2	20
Figura 10 – Demonstração Rede SOM: Parte 3	21
Figura 11 – Demonstração Rede SOM: Parte 4	22
Figura 12 – Histórico Escolar Turma 2004-2005	24
Figura 13 – Arquivo texto das notas gerado a partir do Histórico	24
Figura 14 – Média geral dos alunos	27
Figura 15 – Demonstração do resultado na Época 0	28
Figura 16 – Demonstração do resultado na Época 1000	29
Figura 17 – Demonstração do resultado na Época 5000	29
Figura 18 – Demonstração do resultado na Época 9999	30
Figura 19 – Grupos formados após execução	31
Figura 20 – Resultado execução 2	32
Figura 21 – Resultado execução 3	32

1 INTRODUÇÃO

Pode-se afirmar que os computadores são ferramentas que auxiliam em nosso dia-a-dia, em casa, no comércio, nas indústrias, no governo, nas instituições de ensino, entre outros. É sabido que os computadores processam volumosas quantidades de dados e que nos fornecem informações para que possamos tomar decisões. O computador por si só, não é capaz de pensar como o ser humano. Não é capaz de interpretar dados, fazer análises, comparações e tomar decisões, agindo de forma inteligente.

A Inteligência Artificial (IA) é uma ciência que tem por princípio dotar os computadores de inteligência, para que possam se tornar mais úteis, realizando tarefas que competiam apenas aos seres humanos realizar. Tem se tornado alvo de estudos devido sua evolução e utilidade ao ser implementado em diversas áreas e segmentos como robótica, previsão em mercado financeiro, controles de segurança, tratamento de imagens, extração de características, classificação, mineração de dados, etc.

Redes Neurais Artificiais (RNAs) é uma sub-área de IA que estuda o funcionamento do cérebro humano. É baseado em características encontradas nos neurônios e seus componentes biológicos. São implementados em sistemas para que estes possam se comportar de forma inteligente, agindo, aprendendo, reconhecendo, de forma análoga ao cérebro humano. Logo, uma máquina que é capaz de aprender, interagir com o ambiente externo, errar como o ser humano, aprender com os erros e corrigi-los, adquirir conhecimentos do mundo e usá-los para processar informações, esta máquina seria considerada inteligente.

Para permitir um maior conhecimento sobre os alunos de uma Instituição de Ensino Superior, este projeto tem por finalidade desenvolver uma aplicação utilizando Redes Neurais Artificiais para classificar os alunos em grupos, observando suas médias em cada disciplina. Dessa maneira é possível traçar um perfil para cada aluno e qualificá-los como bons, ruins, e médios alunos, considerando suas notas. Para um aluno que sempre se encontra em determinado grupo, e após um tempo (no decorrer do curso) se afasta daquele grupo, ou literalmente vai para outro grupo, é sinal de mudança de padrão daquele aluno, dependendo da situação, para melhor ou pior, facilitando a identificação de tal acontecimento por parte da coordenação do curso. E que, por fim, possa a Instituição conhecer melhor seus alunos, indicar e direcionar seu foco.

Este trabalho está dividido em sete (7) capítulos. No capítulo 1 é dada uma introdução ao tema, explanando sobre os objetivos do trabalho. No capítulo 2 é tratado superficialmente sobre os conceitos de inteligência artificial. No capítulo 3 é tratado sobre redes neurais artificiais, sua arquitetura, seus modelos e seus métodos. No capítulo 4 é abordado sobre o desenvolvimento do trabalho. No capítulo 5 são demonstrados os resultados obtidos. No capítulo 6 é apresentada a conclusão do trabalho, a discussão dos resultados e os trabalhos futuros a serem desenvolvidos. No capítulo 7 está relacionada toda a bibliografia pesquisada.

2 INTELIGÊNCIA ARTIFICIAL (IA)

O objetivo da IA é o estudo e a modelagem da inteligência tratada como um fenômeno. A inteligência é algo extremamente complexo, resultado de milhões de anos de evolução. Entendê-la não é tarefa fácil. Embora existam muitas conclusões relevantes, ainda há muito a ser desvendado, uma vez que não existe uma teoria completa sobre a mente humana e os processos de raciocínio. [FERNANDES, 2003]

A inteligência humana está aliada à sua capacidade de se interagir com o meio através de habilidades cognitivas (sentidos) e conotativas (ação), ou seja, se movimentar, reconhecer sons (fala) e imagens, se expressar, etc. Existe um esforço, principalmente no campo da robótica, no sentido de implementar essas habilidades nas máquinas inteligentes, de modo a propiciar uma maior interação com o meio e desenvolver padrões de inteligência envolvidos na aquisição do conhecimento, reconhecimento, aprendizado, etc. [FERNANDES, 2003]

Como definição, pode-se dizer que IA é a parte da ciência da computação voltada para o desenvolvimento de sistemas de computadores inteligentes, isto é, sistemas que exibem características, as quais se associam com a inteligência no comportamento humano – por exemplo: compreensão da linguagem, aprendizado, raciocínio, resolução de problemas, etc.

2.1 Abordagens da Inteligência Artificial

Baseado nos diversos campos de estudo que ajudaram na fundamentação dos princípios teóricos da inteligência artificial, são apontadas duas abordagens para IA:

- Abordagem cognitiva ou simbolista: dá ênfase aos processos cognitivos, ou seja, a forma como o ser humano raciocina. Objetiva encontrar uma explicação para comportamentos inteligentes baseados em aspectos psicológicos e processos algorítmicos. Os pioneiros desta corrente foram John McCarthy, Marvin Minsky, Newell e Simon.
- Abordagem conexionista, que é o foco desse trabalho, dá ênfase no modelo de funcionamento do cérebro, dos neurônios e das conexões neurais. Os pioneiros desta corrente foram McCulloch, Pitts, Helder, Rosenblatt e Widrow. Em 1943 surgiu a

representação e formalização matemática dos neurônios, que fez surgir os primeiros modelos de redes neurais artificiais. [FERNANDES, 2003]

A abordagem conexionista é tratada no próximo capítulo, com ênfase nas redes neurais artificiais.

3 REDES NEURAIS ARTIFICIAIS (RNAs)

Para entender melhor a definição de RNA é relevante conhecer os conceitos de três palavras “chaves”: neurônio, arquitetura e aprendizagem, onde o neurônio é a unidade computacional básica de uma rede; a arquitetura é a estrutura topológica de como os neurônios estão conectados; e a aprendizagem é um processo que adapta a rede de modo a computar uma função desejada ou realizar uma tarefa. [FERNANDES, 2003]

Esta forma de computação não-algorítmica é caracterizada por sistemas que, em algum nível, relembram a estrutura do cérebro humano. Por não ser baseada em regras ou programas, a computação neural se constitui em uma alternativa à computação algorítmica convencional. [BRAGA, 2000]

3.1 Neurônio

Uma rede neural artificial é composta por várias unidades de processamento (neurônio), cujo funcionamento é simples. Essas unidades, geralmente são conectadas por canais de comunicação que estão associados a determinado peso. As unidades fazem operações apenas sobre seus dados locais, que são entradas recebidas pelas suas conexões. O comportamento inteligente de uma Rede Neural Artificial vem das interações entre as unidades de processamento da rede. [FERNANDES, 2003]

Em 1943 surgiu a representação matemática dos neurônios, proposta por McCulloch e Pitts (Figura 1):




Figura 1 – Representação matemática do neurônio – McCulloch e Pitts.

Fonte: [TATIBANA]

A operação de uma unidade de processamento pode ser resumida da seguinte maneira:

- Sinais (X_i) são apresentados à entrada;
- Cada sinal é multiplicado por um número, ou peso (W_i), que indica sua influência na saída da unidade;
- É feita a soma ponderada dos sinais que produz um nível de atividade. $(a) = \sum X_i.W_i$
- Se este nível de atividade exceder um certo limite, chamado de *threshold* (Θ), a unidade produz uma determinada resposta de saída (Y).

A maioria dos modelos de redes neurais possui alguma regra de treinamento, onde os pesos de suas conexões são ajustados de acordo com os padrões apresentados. Regras de treinamento serão discutidas mais adiante.

3.2 Arquitetura de uma RNA

Arquiteturas de redes neurais são tipicamente organizadas em camadas, com unidades que podem estar conectadas às unidades da camada posterior (Figura 2):




Figura 2 – Camadas de uma Rede Neural Artificial (RNA).

Fonte: [TATIBANA]

Geralmente uma RNA possui três camadas, que são: camada de entrada; camada intermediária; e camada de saída. Onde, na camada de entrada são apresentados os

padrões; nas camadas intermediárias é realizada a maior parte do processamento através das conexões ponderadas, e, na camada de saída o resultado final é concluído e apresentado.

É importante salientar que a arquitetura apresentada na figura 2 é um modelo genérico, que pode ter suas variações de acordo com os paradigmas de outros modelos de RNAs.

3.3 Aprendizagem

As regras de aprendizagem ou treinamento são conjuntos de procedimentos bem definidos para adaptar os parâmetros de uma RNA para que a mesma possa aprender uma determinada função. Estes conjuntos são chamados de algoritmos de aprendizado.

A utilização de uma RNA na solução de uma tarefa passa inicialmente por uma fase de aprendizagem, ou treinamento, quando a rede extrai informações relevantes de padrões de informação apresentados para ela, criando assim uma representação própria para o problema. A etapa de aprendizagem consiste em um processo iterativo de ajuste de parâmetros da rede, os pesos das conexões entre as unidades de processamento, que guardam, ao final do processo, o conhecimento que a rede adquiriu do ambiente em que está operando. [BRAGA, 2000]

Diversos métodos para treinamento de redes foram desenvolvidos, podendo ser agrupados em dois paradigmas principais, que são:

Supervisionado: neste tipo de treinamento, além das entradas que são fornecidas à rede, são também fornecidas as saídas desejadas para essa entrada, por um “professor” externo. O objetivo é ajustar os parâmetros da rede, de forma a encontrar uma ligação entre os pares de entrada e saída fornecidos. A cada padrão de entrada submetido à rede compara-se a resposta desejada. No caso de erro, os pesos das conexões são ajustados para minimizá-lo. Os ajustes são feitos a cada etapa do treinamento de forma que estes caminhem para uma solução, se houver. A desvantagem deste tipo de treinamento é que, na ausência do professor, a rede não conseguirá aprender novas estratégias para situações não cobertas pelos exemplos do treinamento da rede. A Figura 3 ilustra esta idéia.




Figura 3 – Treinamento Supervisionado

Fonte: [NAVAUX]

Não-Supervisionado: como o próprio nome sugere, neste não há um professor ou supervisor para acompanhar o processo de aprendizado. Para este tipo de treinamento, somente os padrões de entrada estarão disponíveis para a rede, ao contrário do treinamento supervisionado. A rede torna-se capaz de formar representações internas para codificar características de entrada e criar novas classes ou grupos automaticamente, mas para isso, é necessário que haja redundância dos dados de entrada. Sem essa redundância seria impossível encontrar quaisquer padrões ou características dos dados de entrada. A Figura 4 ilustra esta idéia. [BRAGA, 2000]




Figura 4 – Treinamento Não-Supervisionado

Fonte: [NAVAUX]

Neste trabalho deverá ser utilizada obrigatoriamente uma rede não supervisionada, pois, espera-se que a rede encontre os agrupamentos dentre os alunos, a partir de suas notas, sem que haja orientação de um “professor” sobre os agrupamentos desejados. Apresenta-se a seguir um modelo clássico de rede não-supervisionada.

3.4 Redes SOM (*Self-organizing Maps*)

As Redes SOM (*Self-organizing Maps*) são modelos de redes auto-organizáveis ou auto-associativas e foram desenvolvidas por Teuvo Kohonen na década de 80. Essas redes possuem forte inspiração neurofisiológica e funcionam basicamente da seguinte forma: quando um padrão de entrada \mathbf{p} é apresentado, a rede procura a unidade mais parecida com \mathbf{p} . Durante o seu treinamento, a rede aumenta a semelhança do nodo escolhido e de seus vizinhos ao padrão \mathbf{p} . Desta forma, a rede constrói um mapa topológico onde nodos que estão topologicamente próximos respondem de forma semelhante a padrões de entrada semelhantes.

A rede SOM utiliza um algoritmo de aprendizado competitivo, onde os nodos da camada de saída competem entre si para se tornarem ativos, ou seja, para ver quem gera o maior valor de saída. Assim, para cada padrão de entrada apenas um nodo de saída ou nodo por grupo se torna ativo. Esta competição é chamada de *winner-takes-all* (o vencedor leva tudo). [NAVAUX]

3.4.1 Arquitetura das Redes SOM

A rede de Kohonen (rede SOM) é dividida em duas camadas: a camada de entrada (X_i) e a camada competitiva de neurônios, conforme mostra a Figura 5. Cada neurônio da camada competitiva está conectado a todos os neurônios da camada de entrada por vetores de pesos sinápticos (W_{ij}) que são ajustados por um processo de aprendizado do tipo não-supervisionado.




Figura 5 – Camadas que compõem a rede de Kohonen.

Os nodos se organizam em uma grade ou reticulado, geralmente bidimensional, podendo algumas vezes ser unidimensional. Cada nodo da rede recebe todas as

entradas e funciona como um discriminador ou extrator de características. Quanto mais semelhante for a entrada dos pesos de um nodo, maior a saída produzida pelo nodo. A saída da rede é formada pela saída de todos os seus nodos. Durante a fase de aprendizagem, os nodos se especializam para a detecção de uma série de padrões de entrada. Os nodos se organizam topologicamente, fazendo com que padrões detectados por um dado nodo estejam relacionados com a coordenada da posição do nodo dentro da rede. Desta forma, um mapa de características *self-organizing* forma mapas topológicos de padrões de entrada, onde padrões semelhantes são detectados por nodos próximos do reticulado. Assim, as localizações espaciais dos nodos correspondem a características dos padrões de entrada, daí o nome mapa de características *self-organizing*. [BRAGA, 2000]

3.4.2 Treinamento das Redes SOM

Para fazer o treinamento, um padrão de entrada é apresentado à rede e, através do algoritmo de competição, os nodos competem entre si para ver quem mais se assemelha à entrada apresentada. O mais próximo se torna o vencedor e após o processo de seleção, os pesos do nodo vencedor e de seus vizinhos são ajustados, de forma a tornarem-se mais semelhantes ao padrão de entrada. O ajuste destes pesos provê a auto-organização da rede neural.

Para melhorar o desempenho da rede, utiliza-se uma taxa de aprendizado que vai decrementando na proporção em que a rede vai sendo treinada e o raio de vizinhança dos nodos que dinamicamente vai se modificando, diminuindo o raio a cada N iterações. Segue abaixo, o algoritmo resumido do treinamento da rede SOM (Figura 6). [BRAGA, 2000]

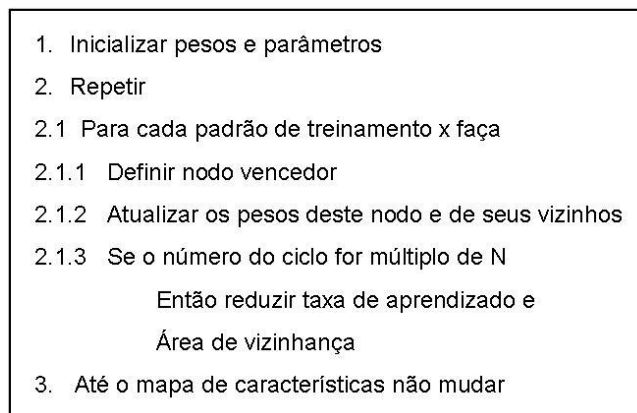


Figura 6 – Algoritmo treinamento SOM

Os pesos iniciais devem ser escolhidos aleatoriamente e os parâmetros a serem ajustados incluem a taxa de aprendizagem, o número de épocas de treinamento, o raio

da vizinhança afetada no aprendizado, e a velocidade de decaimento desta vizinhança. Após várias apresentações do conjunto de treinamento, os vetores de pesos tendem a seguir as distribuições dos vetores de entrada.

O treinamento da rede SOM ocorre em duas fases: fase de ordenação e fase de convergência. Durante a fase ordenação, ocorre a ordenação topológica dos vetores de pesos. Esta fase busca agrupar os nodos do mapa topológico em *clusters* ou agrupamentos, de modo a refletir a distribuição dos padrões de entrada. Assim, a rede descobre quantos *clusters* ela deve identificar e suas posições relativas no mapa. Nesta fase ocorre também a redução da vizinhança, que a princípio envolve todos os nodos da rede - ainda que atingindo mais fortemente os mais próximos, de forma semelhante a uma curva normal - até atingir um raio de um ou dois vizinhos (Figura 7).




Figura 7 – Redução da região de vizinhança.

A segunda fase faz um ajuste mais fino do mapa, aprimorando o agrupamento realizado na fase anterior, tornando cada *cluster* mais semelhante aos padrões de entrada nele armazenados.

3.5 Demonstração do funcionamento das Redes SOM

Na sequência, segue uma demonstração do funcionamento da rede de Kohonen:




Figura 8 – Demonstração Rede SOM: Parte 1.

Fonte: [ARANHA, 1999]

Considerando que a rede seja inicializada, com valores aleatórios em seus pesos, a Figura 8 mostra um conjunto de dados que será apresentado à rede. Neste caso os dados são pessoas de sexo e idade variados: homens, mulheres, meninos e meninas.




Figura 9 – Demonstração Rede SOM – Parte 2.

Fonte: [ARANHA, 1999]

Conforme a Figura 9, primeiramente é apresentada à rede uma única pessoa. O neurônio que reage mais fortemente “ganha”, ou seja, aquele que mais se assemelha à entrada apresentada. Dessa forma, o neurônio vencedor e seus vizinhos têm os seus pesos ajustados, conforme indicam as setas vermelhas.




Figura 10 – Demonstração Rede SOM – Parte 3.

Fonte: [ARANHA, 1999]

Conforme mostra a Figura 10, novamente outra pessoa é apresentada à rede e da mesma forma que anteriormente, o neurônio que reage mais fortemente “ganha” e tem o seu peso e de seus vizinhos ajustados.



Figura 11 – Demonstração Rede SOM – Parte 4.

Fonte: [ARANHA, 1999]

Conforme Figura 11, após apresentar todas as pessoas à rede, estas são organizadas e agrupadas conforme suas características.

Portanto, a rede foi capaz de se auto-organizar, extraindo características dos padrões de entrada, formando os grupos.

4 DESENVOLVIMENTO

A proposta do trabalho, como já mencionado anteriormente, é desenvolver uma aplicação utilizando redes neurais artificiais, que seja capaz de encontrar características em alunos, baseando-se somente em notas obtidas no histórico escolar da turma a ser avaliada pelo programa. A rede neural deve qualificá-los e agrupá-los conforme seu desempenho durante o curso.

Para iniciar o projeto, primeiramente foi necessário definir o modelo de rede neural a se utilizar e a linguagem de programação.

O modelo escolhido foi redes de Kohonen (SOM) por ser de fácil implementação e por possuir características que satisfizessem a proposta do trabalho. O programa foi implementado utilizando a linguagem C/C++ e seu código fonte pode ser visto no Apêndice A.

Para que o programa pudesse trabalhar com dados reais, de alunos reais, para melhor avaliar os resultados obtidos, foi utilizado o histórico escolar das turmas formadas em 2004 e 2005 das Faculdades Thathi, que foram obtidos do banco de dados acadêmico e armazenados em um único arquivo, fornecido pela Secretaria das Faculdades Thathi em formato do Excel. A Figura 12 apresenta um trecho deste arquivo que pode ser visto integralmente no Apêndice B.

	RA	Cálculo Diferencial e Integral I	Física I	Geometria Analítica	Inglês Técnico I	Introdução à Ciência da Computação	Linguagem e Técnicas de Programação I	Microinformática	Álgebra Linear	Cálculo Diferencial e Integral II	Estrutura de Dados I	Física II	Inglês Técnico II	Língua Portuguesa I	Lógica Matemática e Aplicações	Probabilidade e Estatística	Estrutura de Dados II	Informática e Sociologia	Língua Portuguesa II
		1	1	1	1	1	1	1	2	2	2	2	2	2	2	2	3	3	3
Alex Aparecido de Carvalho	22	7,75	7,75	7,00	8,25	9,00	8,75	8,25	8,25	8,00	9,50	8,50	8,00	5,50	7,00	8,50	9,25	8,25	5,50
Belchior Cardoso Palma	3	8,20	7,00	6,30	7,70	8,20	7,70	8,20	7,50	7,20	8,70	8,50	8,70	7,20	7,00	7,70	8,20	9,50	5,00
Camila Belussi Ferreira	23	9,00	8,00	8,25	8,25	9,00	7,25	7,75	7,75	9,50	8,75	7,50	8,75	8,25	9,25	8,00	10,00	8,50	6,00
Camila Mayumi Hashiguchi	25	9,50	10,00	8,25	9,75	9,50	9,25	9,00	8,75	10,00	8,50	8,50	9,00	7,50	9,25	9,25	9,50	9,75	7,00
Carlos Henrique Martinelli	57	8,00	8,70	8,20	8,20	8,50	7,50	8,50	8,00	9,50	8,50	7,50	9,00	9,00	8,20	8,70	7,20	8,00	6,60
Clayton Hermínio Miloch	28	8,00	7,75	7,25	8,75	9,00	8,75	8,75	7,50	8,00	8,75	8,75	8,50	7,50	8,25	9,50	10,00	9,50	7,00
Clayton Issamu Kikuchi	31	10,00	10,00	10,00	10,00	10,00	9,50	9,25	9,75	9,75	10,00	10,00	10,00	8,00	10,00	9,75	10,00	9,75	8,75
Deivis Fernandes Pirani	48	7,70	8,20	7,20	9,20	9,00	7,70	8,70	7,00	7,20	8,20	9,20	8,70	7,20	9,00	8,50	7,50	9,00	8,70
Douglas Felício Bertachini	45	8,70	9,20	8,00	8,20	9,70	7,50	8,70	8,70	9,00	8,50	8,70	7,70	7,20	9,70	8,70	8,70	7,70	5,50
Edson Takao Sakuma	34	5,50	7,30	9,50	9,00	7,75	7,75	7,25	7,75	9,50	9,25	9,50	9,00	8,50	9,25	6,50	8,25	7,50	5,00
Eduardo Yoshinori Sakai	41	6,50	7,50	5,62	6,12	6,37	7,00	7,25	7,00	6,25	8,50	7,50	7,00	6,25	7,75	7,25	8,75	7,25	5,50
Edvaldo Costa	43	5,87	7,75	5,37	8,75	7,75	7,50	8,75	7,00	7,37	8,00	7,25	7,00	6,37	6,37	7,00	7,50	7,25	7,00
Fábio Barros Bergamasco	51	5,00	6,00	5,62	8,50	7,00	5,75	7,75	7,50	5,87	7,75	7,25	8,75	7,25	7,50	7,50	7,50	9,25	7,00
Fabrício De Jesus Fagnani	42	6,30	7,00	5,70	8,20	8,00	5,30	7,70	7,20	7,20	7,70	7,20	8,70	5,80	8,20	5,10	7,70	8,20	7,00
Fernanda David Falcão	44	9,75	9,50	8,25	10,00	8,25	8,00	7,75	8,50	9,25	8,75	9,00	9,50	8,50	8,50	8,50	9,00	8,75	8,50
Hélio Rubens Alves De Oliveira	27	8,50	8,25	7,00	9,25	7,50	9,00	8,25	7,50	8,50	7,25	7,50	8,75	8,25	9,25	8,25	9,00	9,50	7,50
Igor de Sousa Pucci	15	8,00	5,20	5,00	8,00	7,50	8,00	7,70	5,00	7,00	7,20	5,50	7,50	7,20	6,00	5,10	7,20	7,50	8,20
Lizandra Maria Ribeiro Lopes	19	9,00	8,00	7,50	8,50	7,50	6,50	8,20	9,50	8,70	8,70	8,50	8,70	7,50	8,50	8,70	8,00	7,70	5,00
Luigui Batista Moterani	2	8,20	9,20	8,00	10,00	10,00	8,70	9,20	9,00	5,50	8,00	8,30	8,00	8,00	8,00	8,00	8,70	9,50	8,00
Luís Gustavo Guedes de Sousa	29	9,75	10,00	10,00	9,75	9,25	9,75	9,25	9,75	9,50	9,00	9,00	9,25	7,75	9,25	8,75	9,50	9,00	6,50
Mariana Simonucci	54	8,70	9,50	8,70	9,70	8,70	7,70	9,20	10,00	10,00	7,50	8,00	9,50	7,70	10,00	9,00	8,00	7,00	5,00
Maycoln Araújo	9	8,00	7,70	6,10	7,20	8,50	7,70	8,00	7,00	5,60	7,20	8,00	7,70	7,70	7,20	5,00	7,20	7,00	7,50
Paulo De Castro Mazarin	36	8,25	8,75	6,75	9,25	8,00	8,25	9,00	7,00	7,25	9,25	8,25	9,00	7,50	8,75	8,00	9,25	7,25	7,50
Renato Lopes Spereta	32	5,87	8,00	5,37	7,50	7,00	7,37	7,75	6,12	5,75	7,75	7,00	8,50	7,00	7,50	7,00	7,25	7,25	5,37
Rodrigo Matos Miller	37	7,00	9,50	6,12	8,00	7,75	7,75	9,00	5,37	8,25	8,00	8,00	7,00	6,62	8,00	6,12	7,00	8,75	7,00

Figura 12 – Histórico Escolar Turma 2004-2005.

Neste arquivo constam dados de vinte e cinco (25) alunos com quarenta e oito (48) disciplinas, contendo a média do aluno em cada disciplina. A partir deste arquivo foi gerado outro, em formato texto, contendo somente as notas, sendo que em cada linha constam todas as notas de um aluno. A Figura 13 apresenta um trecho deste arquivo, que pode ser visto integralmente no Apêndice C.

Arquivo	Editar	Formatar	Exibir	Ajuda
7.75	7.75	7.00	8.25	9.00
8.20	7.00	6.30	7.70	8.20
9.00	8.00	8.25	8.25	9.00
9.50	10.00	8.25	9.75	9.50
8.00	8.70	8.20	8.20	8.50
8.00	7.75	7.25	8.75	9.00
10.00	10.00	10.00	10.00	9.50
7.70	8.20	7.20	9.20	9.00
8.70	9.20	8.00	8.20	9.70
5.50	7.30	9.50	9.00	7.75
6.50	7.50	5.62	6.12	6.37
5.87	7.75	5.37	8.75	7.75
5.00	6.00	5.62	8.50	7.00
6.30	7.00	5.70	8.20	8.00
9.75	9.50	8.25	10.00	8.25
8.50	8.25	7.00	9.25	7.50
8.00	5.20	5.00	8.00	7.50
9.00	8.00	7.50	8.50	7.50
8.20	9.20	8.00	10.00	10.00
9.75	10.00	10.00	9.75	9.25
8.70	9.50	8.70	9.70	8.70
8.00	7.70	6.10	7.20	8.50
8.25	8.75	6.75	9.25	8.00
5.87	8.00	5.37	7.50	7.00
7.00	9.50	6.12	8.00	7.75

Figura 13 – Arquivo texto das notas gerado a partir do Histórico.

Este arquivo chamado 'alunotas.txt' é utilizado pelo programa em tempo de execução para compor a matriz de entrada (X_{ij}). Veja código abaixo:

```
void criaEntradas(float entradas[nEntradas][notas]){
    int i,nota;
    infile.open("alunotas.txt", ios::in); //faz a leitura do arquivo texto "alunotas.txt"
    for (i=0;i<nEntradas;i++) // cria entradas
        for (nota=0; nota<notas; nota++)
            infile>>entradas[i][nota];
}
```

Neste trecho do código, a função criaEntradas cria a matriz de entrada com os valores (notas) que são lidos do arquivo 'alunotas.txt' através do comando infile e que tem como parâmetros as variáveis nEntradas e notas que já possuem seus valores definidos no escopo do programa.

Para o treinamento da matriz de pesos tridimensional com as dimensões 10 x 10 x 48, ou seja, $w[10][10][48]$, foram configurados os parâmetros da rede após muitas tentativas e análise dos resultados obtidos, para que o programa pudesse ser executado com boa capacidade de agrupamento dos dados. Estes parâmetros dizem respeito aos pesos iniciais dos neurônios, taxa de aprendizado, raio de vizinhança, tamanho da matriz de pesos, número de épocas de treinamento, decaimento da vizinhança, entre outros. Para a taxa de aprendizado inicial, foi estabelecido o valor de 0,05 a ser decrementado suavemente a cada iteração. O raio de vizinhança inicial é de 10, a ser decrementado proporcionalmente ao número de épocas transcorridas, até chegar ao valor mínimo de 2. A matriz de pesos será inicializada com valores aleatórios que variam de 5 a 10 por serem valores semelhantes às notas existentes nos arquivos de entrada e assim tornar o treinamento mais rápido. O número de iterações para o treinamento, neste caso chamado de 'Época' é de 10000, ou seja, o programa apresenta dez mil vezes (10000) a mesma matriz de entrada à rede. Veja código abaixo:

```
#define dimW 10 // w é uma matriz quadrada
#define notas 48 // quantidade de notas na terceira dimensao do vetor W
#define nEntradas 25
#define nEpocas 10000
#define rangeInicial 10
```

#define rangeFinal 2

Neste código estão definidos a dimensão da matriz de pesos, o número de épocas, os raios de vizinhança inicial e final, e a definição dos valores para as variáveis nEntradas e notas, mencionadas anteriormente.

O programa lê todas as notas de determinado aluno; compara com todas as posições da matriz de pesos e encontra a posição que mais se assemelha ao vetor apresentado, ou seja, vence aquela posição em que a soma das diferenças absolutas entre a nota e o peso de cada disciplina seja menor. Os pesos do vencedor e de seus vizinhos são ajustados, conforme a taxa de aprendizado. O mesmo procedimento se repete para cada um dos outros alunos, repetindo-se este processo em cada uma das Épocas.

Ao final da execução do programa, é mostrado qual posição da matriz venceu a competição para cada aluno, devendo, portanto, para o sucesso do trabalho, os alunos com melhores médias estarem em regiões próximas entre si na matriz e ao mesmo tempo afastados dos alunos com piores médias, formando assim os grupos de alunos bons, ruins, e, médios.

5 RESULTADOS

Para avaliar os resultados, vamos considerar uma média geral para cada aluno e qualificá-los numa escala de melhor à pior aluno (Figura 14).

MÉDIA GERAL DOS ALUNOS CONSIDERANDO AS 48 DISCIPLINAS	
Ordem Original	Classificado por Notas
Alex 8,18	Clayton Kikuchi 9,77
Belchior 7,77	Luís Gustavo 9,14
Camila Belussi 8,22	Fernanda 8,80
Camila Mayumi 8,57	Clayton Miloch 8,72
Carlos 8,35	Deivis 8,63
Clayton Miloch 8,72	Camila Mayumi 8,57
Clayton Kikuchi 9,77	Mariana 8,40
Deivis 8,63	Carlos 8,35
Douglas 8,18	Camila Belussi 8,22
Edson 7,98	Luigui 8,19
Eduardo 7,03	Alex 8,18
Edwaldo 7,35	Douglas 8,18
Fábio 7,83	Paulo 8,06
Fabício 7,37	Edson 7,98
Fernanda 8,80	Hélio 7,95
Hélio 7,95	Lizandra 7,85
Igor 7,19	Fábio 7,83
Lizandra 7,85	Belchior 7,77
Luigui 8,19	Rodrigo 7,77
Luís Gustavo 9,14	Maycoln 7,38
Mariana 8,40	Fabício 7,37
Maycoln 7,38	Edwaldo 7,35
Paulo 8,06	Renato 7,32
Renato 7,32	Igor 7,19
Rodrigo 7,77	Eduardo 7,03

Figura 14 – Média geral dos alunos.

Após a execução do programa, os resultados obtidos foram os seguintes:

Época 0 (Figura 15):

			Eduardo Edwaldo						
Fabício Maycoln Rodrigo				Renato	Fábio				
		Igor	Douglas				Belchior		
						Hélio Paulo	Camila Belussi Edson	Mariana	
Alex						Carlos Deivis	Lizandra Luigui		
						Clayton Miloch	Camila Mayumi		
							Fernanda		
				Gustavo					
					Clayton Kikuchi				

Figura 15 – Demonstração do resultado na Época 0.

O programa apresenta seus resultados como um *log* de execução em um arquivo texto (Apêndice D), porém, para melhor visualização, os resultados foram desenhados numa matriz 10 x 10, onde cada nome se encontra em uma posição da matriz. Para melhor acompanhar o processo de aprendizado, os seis melhores alunos estão representados na cor azul, e os seis piores alunos na cor vermelha.

Este gráfico representa o início da execução (Época 0). Pode-se observar que há um esboço de agrupamento, mas não sendo ainda possível identificar nenhum grupo.

Época 1000 (Figura 16):

Eduardo	Igor		Rodrigo		Hélio		Lizandra	Douglas	Mariana
Edwaldo	Maycoln			Edson					
Fabício	Renato								
	Fábio								
									Carlos
Belchior						Camila Belussi			
			Paulo						
									Deivis
Alex									
									Fernanda
Luigui						Clayton Miloch	Clayton Kikuchi		
						Camila Mayumi	Gustavo		

Figura 16 – Demonstração do resultado na Época 1000.

Na Época 1000 já é possível observar que os alunos “azuis” se encontram todos próximos e em extremos opostos dos “vermelhos” que também se encontram agrupados. No entanto, ainda não é suficiente, pois, alguns alunos ainda se encontram mal posicionados. Ainda é necessário um ajuste fino da rede.

Época 5000 (Figura 17):

Fabício		Renato		Belchior			Douglas		Mariana
Igor							Lizandra		
Maycoln									
	Eduardo								
	Edwaldo	Rodrigo						Carlos	
Fábio				Alex					
									Deivis
Edson									
Hélio			Camila Belussi						Fernanda
Paulo									
Luigui			Camila Mayumi		Clayton Miloch			Clayton Kikuchi	
							Gustavo		

Figura 17 – Demonstração do resultado na Época 5000.

Na Época 5000, metade do treinamento, a mudança já não é tão notável. A taxa de aprendizado e a região de vizinhança vão diminuindo. A tendência a partir deste ponto é a taxa de aprendizado e a região de vizinhança diminuir cada vez mais, de modo a estabilizar a rede, fazendo um ajuste fino.

Época 9999 (Figura 18):

Igor Maycoln			Fabício		Belchior		Lizandra		Mariana
		Renato				Douglas			
Eduardo Edwaldo			Rodrigo				Carlos		Deivis
				Alex					
						Camila Belussi			
Fábio			Edson						Fernanda
	Paulo								
						Clayton Miloch		Gustavo	
Luigui			Hélio		Camila Mayumi				Clayton Kikuchi

Figura 18 – Demonstração do resultado na Época 9999.

Na Época 9999, a última, a rede já está treinada e os grupos formados podem ser visualizados (Figura 19):




Figura 19 – Grupos formados após execução.

Traçando duas faixas, azul e vermelha, como ilustra a Figura 19, é possível observar claramente os grupos formados: no canto inferior direito, os azuis (bons alunos); no canto superior esquerdo, os vermelhos (alunos ruins); e no “corredor” que se formou, ficaram os alunos intermediários.

A rede neural encontrou características nestes alunos que os dispusessem desta forma na matriz.

5.1 Outras Análises

Para testar, o programa foi executado diversas vezes a fim de observar o comportamento da rede neural. Observou-se que os resultados eram sempre parecidos, com algumas variações quanto às posições dos alunos, porém, os grupos se mantinham.




Figura 20 – Resultado execução 2.

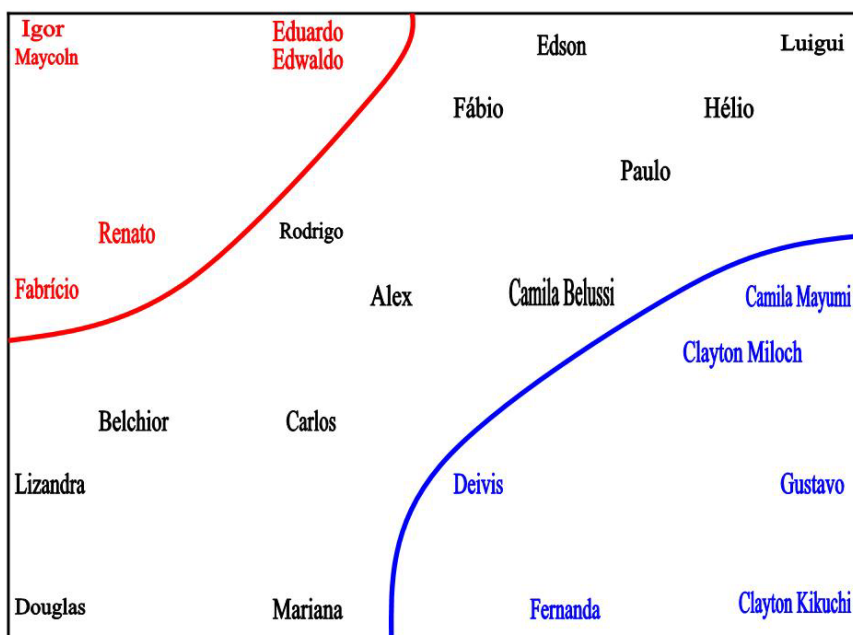


Figura 21 – Resultado execução 3.

Observa-se nas Figuras 20 e 21, que em outras execuções houve mudanças quanto ao sentido dos grupos nas coordenadas do mapa, entretanto, tanto os alunos “azuis” quanto os “vermelhos” se mantiveram próximos, apenas com variações nas posições da matriz.

É possível identificar também sub-agrupamentos comuns às diversas execuções, como: Deivis, Fernanda e Carlos; Camila Mayumi e Clayton Miloch; Eduardo e Edwaldo; Lizandra, Douglas e Belchior; Hélio e Paulo.

6 CONCLUSÕES

Com o estudo da inteligência artificial e especificamente de alguns modelos de redes neurais artificiais conclui-se que existe um avanço na tecnologia permitindo a construção de programas que guardam semelhança e mecanismos de aprendizado humano que, auxiliem na tomada de decisões, o que antes só era possível pelo ser humano. Uma aplicação como o projeto deste trabalho pode ajudar muito na administração de uma Instituição de Ensino no que tange às relações entre docente e discente, diretoria, etc. Permite um melhor acompanhamento e controle dos alunos, permite conhecê-los melhor através do perfil traçado pelo sistema, o que seria difícil principalmente em uma instituição com muitos alunos. Cabe ressaltar também que os resultados foram obtidos sem o uso de métodos estatísticos tradicionais, mas que mostraram convergência de resultados.

Neste trabalho foi possível notar a capacidade de aprendizagem e reconhecimento de padrões de uma rede neural artificial. Existem metodologias, “dicas” e “truques” para se fazer a calibração ideal de uma rede. Normalmente a escolha do valor para a taxa de aprendizado, raio de vizinhança, etc, é definido de forma empírica e requer certa experiência por parte do projetista. Quanto maior a interação do projetista com a rede, mais ele a conhece e se torna capaz de prever seu comportamento em relação a cada um dos parâmetros.

6.1 Trabalhos Futuros

Para que esta aplicação tenha melhor usabilidade, é necessário desenvolver uma interface gráfica que aponte os resultados de forma coerente, a serem analisados por usuários comuns, assim como automatizar a extração dos dados de entradas a partir do banco de dados do sistema acadêmico. Objetiva-se também que este possa fazer outros tipos de análises, como por exemplo, verificar as deficiências de um aluno em determinadas disciplinas, ou, as disciplinas em que o aluno demonstra potencial; prever notas futuras para alunos com base no histórico daquela disciplina; analisar perfil de professores; entre outros. Será necessário fazer melhorias no código fonte, otimizando-o e adequando-o de forma a atribuir valores dinamicamente às variáveis, conforme a quantidade de alunos e notas no arquivo de entrada.